Machine Learning · Professional
Курсовая работа · апрель 2026

Прогнозирование спроса на автоматах быстрого питания

Шилин Георгий

КЛЮЧЕВОЙ РЕЗУЛЬТАТ

MAE 0.597

ОТНОСИТЕЛЬНО BASELINE

−16.2%

Test period
2025-12 — 2026-01

КОНТЕКСТ · 01

Бизнес-задача

Загрузка автомата — решение в ежедневном цикле

Ошибка в любую сторону превращается в убыток.

ЛИШНЯЯ ЗАГРУЗКА

11—21 % списаний

Истечение срока годности

НЕДОЗАГРУЗКА

Пустой автомат → потерянные продажи

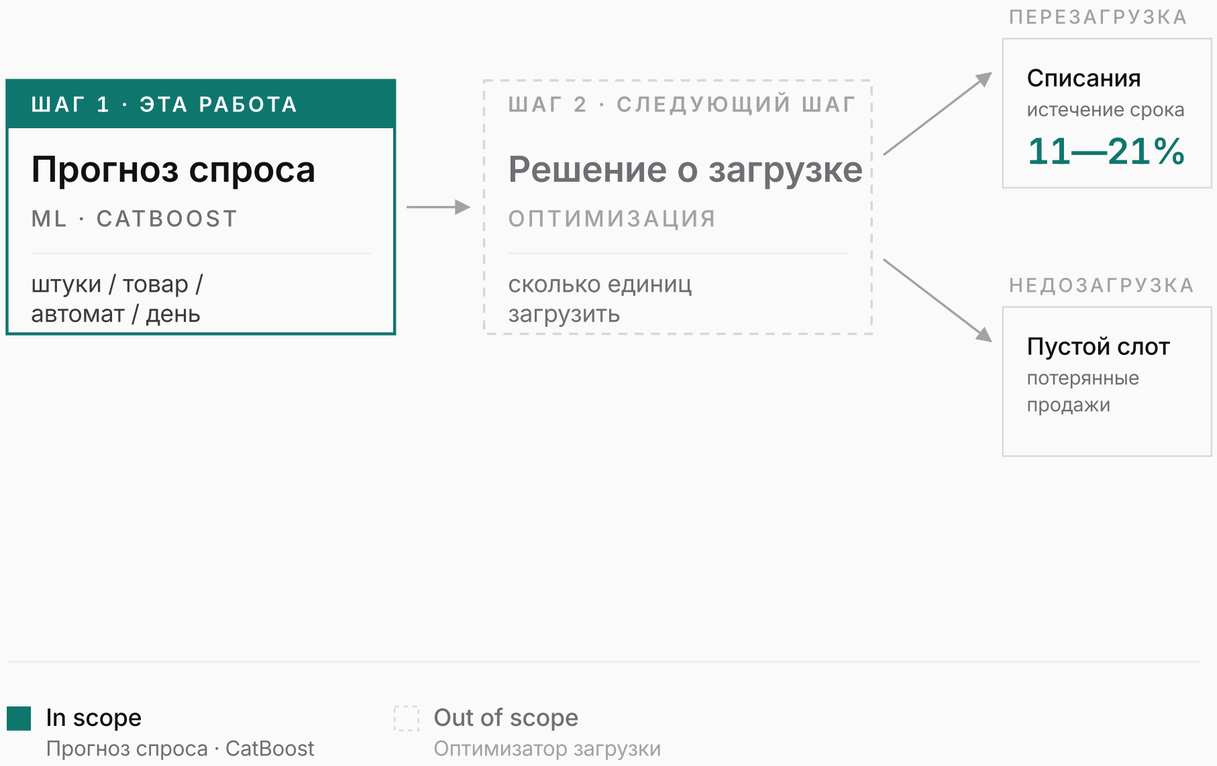

Рис. 1. Прогноз спроса — промежуточный шаг перед решением о загрузке.

ML-задача

ТИП	TARGET	ГРАНУЛЯРНОСТЬ	ГОРИЗОНТ	МЕТРИКА
Регрессия	`total_qty` шт / день	автомат × товар × день	1 день следующая загрузка	MAE штуки → деньги

Почему MAE

Ошибка в штуках напрямую интерпретируется в списания и потерянную выручку. Устойчива к редким выбросам в продажах.

Почему 1 день

Соответствует реальному циклу загрузки. Более длинные горизонты отложены на будущее.

Данные и split

3.46 млн
СТРОК

321
АВТОМАТОВ

890
ТОВАРОВ

Temporal split · строго по времени, без перемешивания

2024-01 ———————— 2026-01

TRAIN	VAL	TEST
2024-01 — 2025-08	2025-09 — 2025-11	2025-12 — 2026-01
20 месяцев	3 месяца	2 месяца

Имитирует продакшен-деплой: модель обучается на прошлом и предсказывает будущее.

Разбиение покрывает будни, выходные и праздничные провалы.

Данные на таймлайне

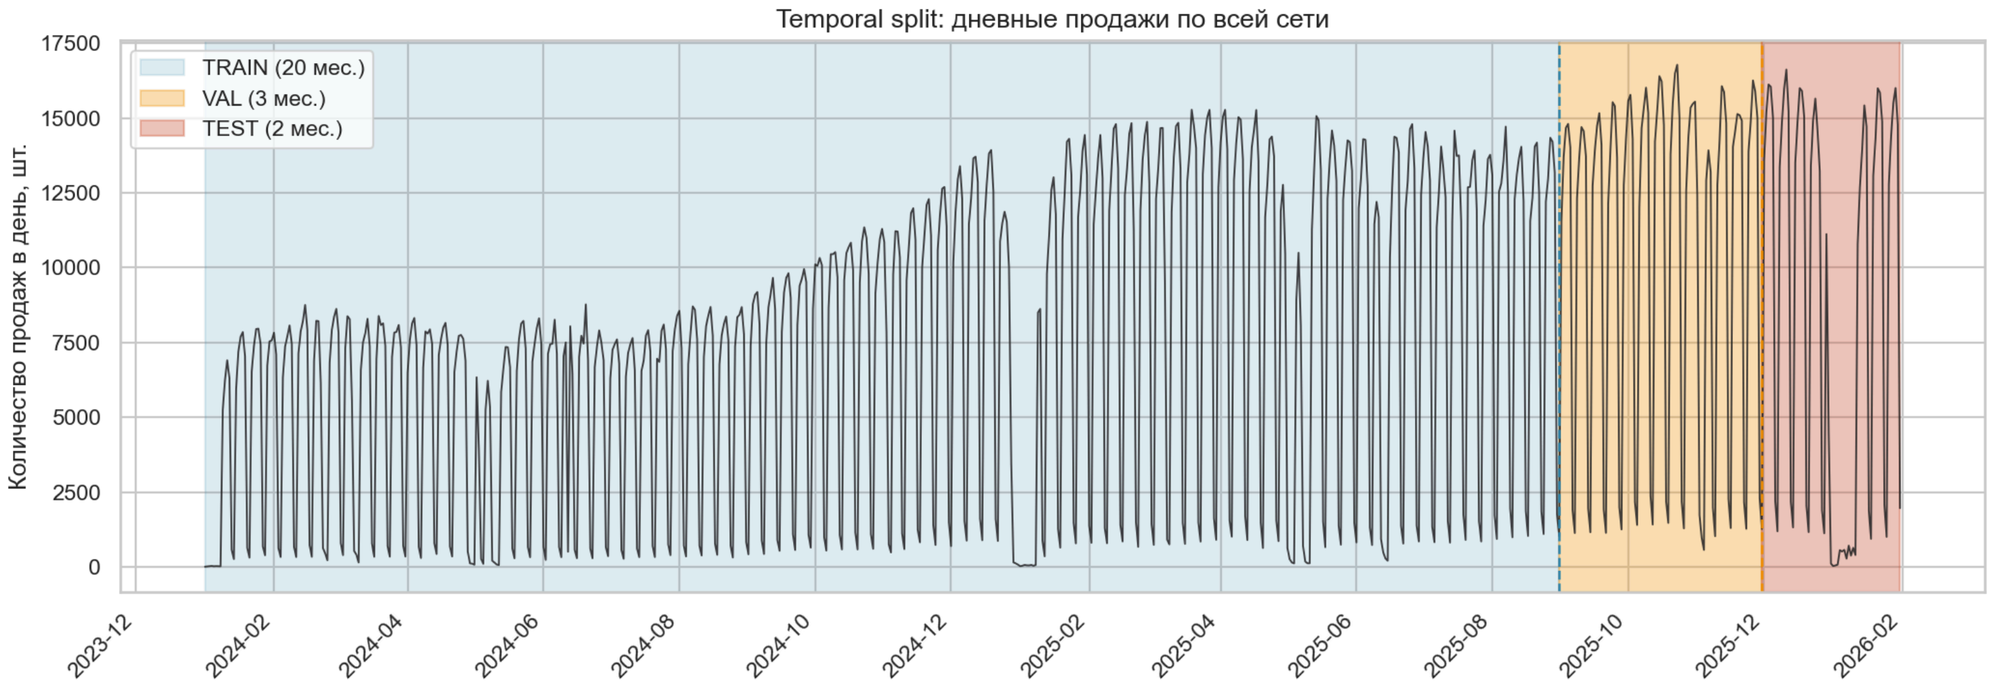

Ежедневные продажи по всей сети, 2024-01 — 2026-01. Подсвечены Train (20 мес.), Val (3 мес.), Test (2 мес.).

Офисный паттерн. Будние пики, провалы на выходных — видно на всём диапазоне.

Split репрезентативен. Val и Test захватывают полные недельные циклы — без искажений на границах.

EDA

1 шт
МЕДИАНА ПРОДАЖ / ДЕНЬ

4 шт
95% ПРОДАЖ ≤

- **Офисный паттерн.** Всплески в будние дни, провалы на выходных.
- **Длинный хвост.** Распределение сильно скошено вправо.
- **Цензурированный спрос.** Ноль продаж ≠ нулевой спрос, когда товар закончился.

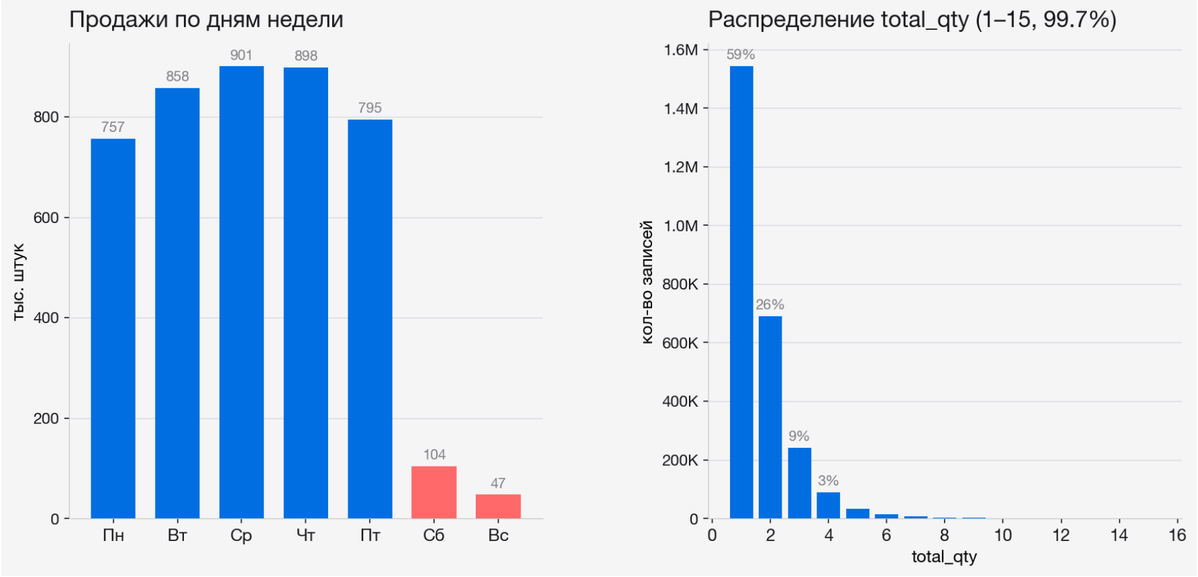

Рис. 2. Офисный паттерн (Сб/Вс в 8× меньше) и распределение `total_qty` (1–15, 99.7%).

Чистка данных: расследование

Что нашли в сырых данных

- **Дубли и тестовые записи.** 161K дублей продаж, 703K дублей остатков.
- **Нестабильные точки.** Сбои передачи данных ≠ падение спроса.
- **Ноль продаж ≠ ноль спроса.** Товар мог просто закончиться.

Чистка данных — не формальность, а отдельное расследование.

161 K
ПРОДАЖИ: ДУБЛИКАТОВ

703 K
ОСТАТКИ: ДУБЛИКАТОВ

9
ФИЛЬТРОВ

сырая БД → подозрения → проверки → источники шума

Что реально улучшило сигнал

Ключевые выводы

- **Данные фиксируют продажи,** а не спрос.
- **Три вида нуля:** нет спроса, нет товара, нет связи.
- **Actual Menu** — полезен как диагностика, не как отдельный признак.
- **Availability** — работает при надёжных данных о загрузке.

Лучший эффект дал не жёсткая чистка, а понимание скрытого спроса.

ПОДХОД	ЭФФЕКТ
Только продажи	Ложные нули
+ контекст остатков/загрузок	Лучший сигнал спроса
+ защищённая логика	**~2% ниже Test MAE**

~2 %

НИЖЕ TEST MAE · ЗАЩИЩЁННЫЙ AVAILABILITY

Предобработка

PostgreSQL → clean → parquet → features → **model**

9
ФИЛЬТРОВ
Невалидные даты, нулевые цены, тестовые автоматы, out-of-scope SKU.

161 K
ДУБЛЕЙ ПРОДАЖ
Дедуплицировано по transaction_id.

703 K
ДУБЛЕЙ ОСТАТКОВ
Снапшоты остатков, свёрнутые по (автомат, товар, дата).

Дедупликация критична: двойной учёт продажи напрямую искажает target.

Feature engineering

23

ПРИЗНАКА · 6 ГРУПП

Категориальные 3

`point_id, goods_id, general_category_name`

Календарные 5

`day_of_week, month, is_weekend, is_holiday, day_of_month`

Лаги 3

`lag_1d, lag_7d, lag_14d`

Rolling 5

`rolling_mean_7d, rolling_mean_14d, rolling_mean_30d, rolling_median_7d, rolling_std_7d`

Остатки 3

`days_since_last_load, last_load_qty, last_expiry_qty`

Цена 4

`avg_price_rub, catalog_price_rub, had_discount, had_promo`

LEAKAGE GUARD · SHIFT(1)

Все лаги и rolling рассчитаны с `.shift(1)` — на момент предсказания в фичах нет информации о целевом дне.

Baseline

МОДЕЛЬ	ОПИСАНИЕ	VAL MAE
Global Mean	Среднее по всему train	0.886
Group Mean	По паре (автомат, товар)	0.755
Lag-1	Продажи вчера	0.784
Rolling Mean 7d	Среднее за последнюю неделю	0.658

Нижняя граница, с которой сравнивается CatBoost.

Лучший простой бейзлайн

0.658

ROLLING MEAN 7D · VAL MAE

Семидневное скользящее среднее уже захватывает недельную сезонность офисного паттерна.

Optuna

TRIALS

53

VAL MAE

0.5623

- Пространство поиска: depth, lr, l2_leaf_reg, subsample
- Лучший trial на validation: Val MAE 0.5623
- Вывод: локальный тюнинг помогает, но не меняет задачу радикально

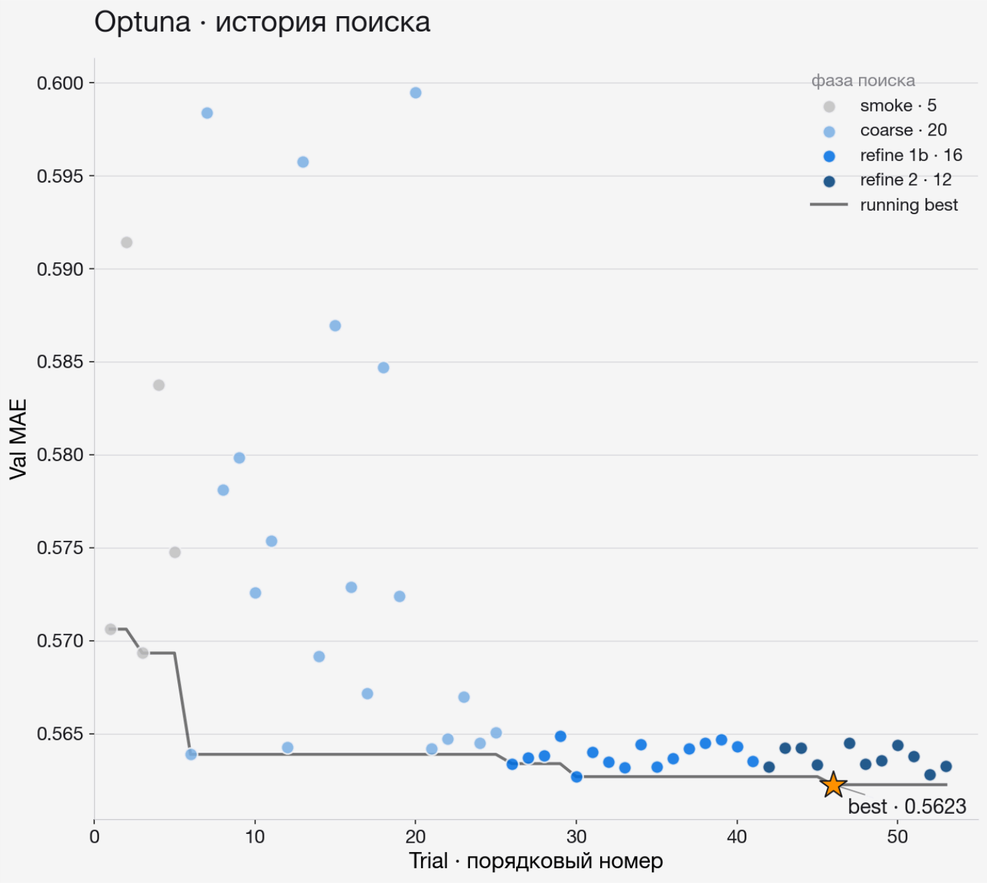

Рис. 3. История оптимизации. Тюнинг помогает локально, но главный резерв качества был не только в гиперпараметрах.

ОСНОВНАЯ МОДЕЛЬ · 12

CatBoost

Финальная модель

0.597 MAE

TEST · 2025-12 — 2026-01

VAL MAE	VS. BASELINE
0.549	−16.2 %

depth	8
iterations	~933 (early stop)
learning_rate	0.05
loss	MAE
cat_features	native

Optuna (53 trials) подтвердил: depth=8 оптимален · Δ = 0.0001

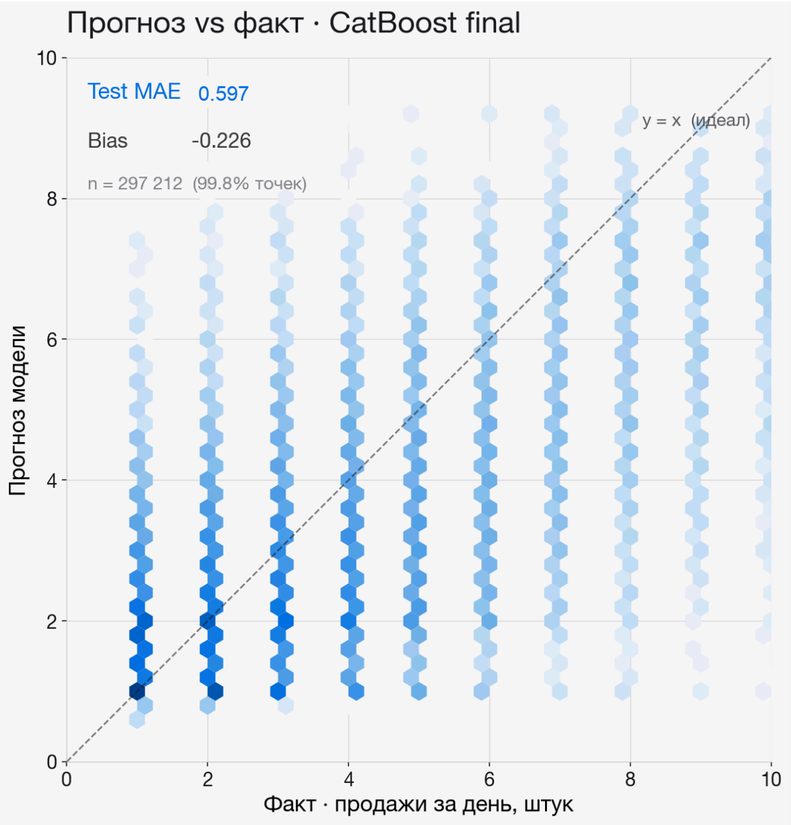

Рис. 4. Прогноз vs факт на тесте. Hexbin, 99.8% точек, диагональ — идеал.

Переобучение

TRAIN MAE

0.492

VAL MAE

0.549

РАЗРЫВ

10.4%

Умеренно. Early stopping остановил рост на ≈933 деревьях.

- L2 регуляризация по умолчанию
- Early stopping по Val MAE, patience 50
- Дальнейшее сокращение gap требует больше данных, не тюнинга

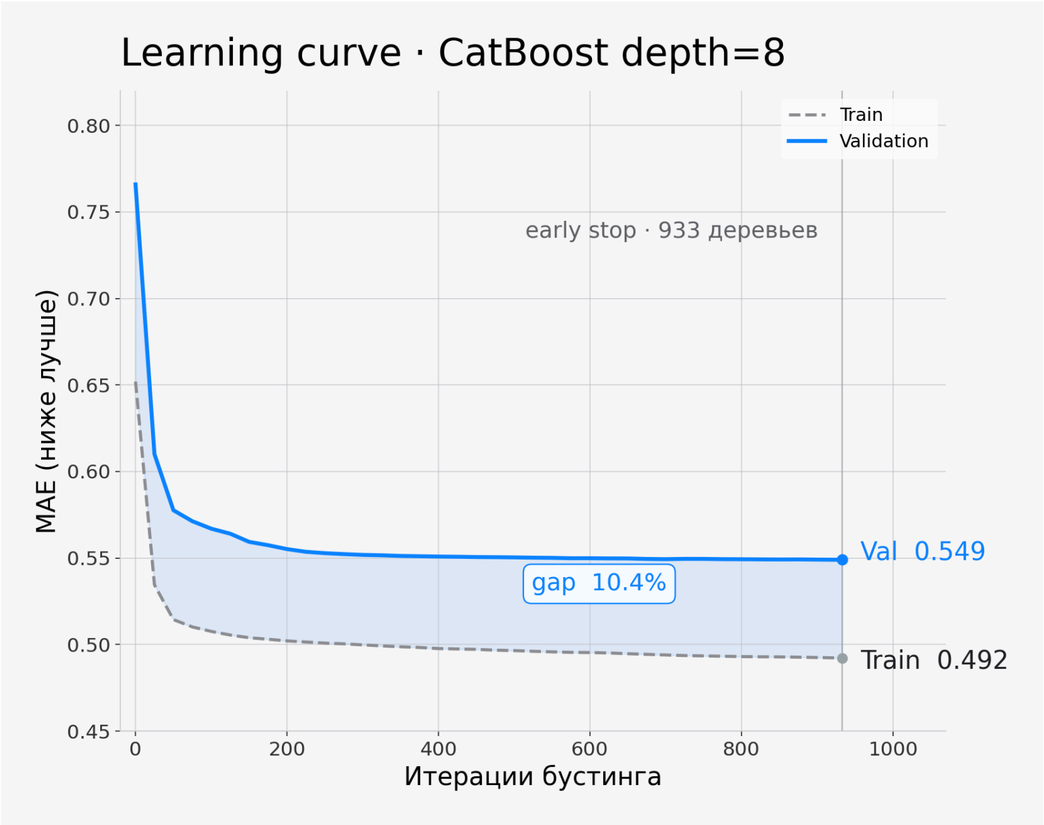

Рис. 5. Learning curve · CatBoost depth=8. Early stopping на ≈933 деревьях; gap 10.4%.

Feature importance и SHAP

Top-7 признаков · доля importance

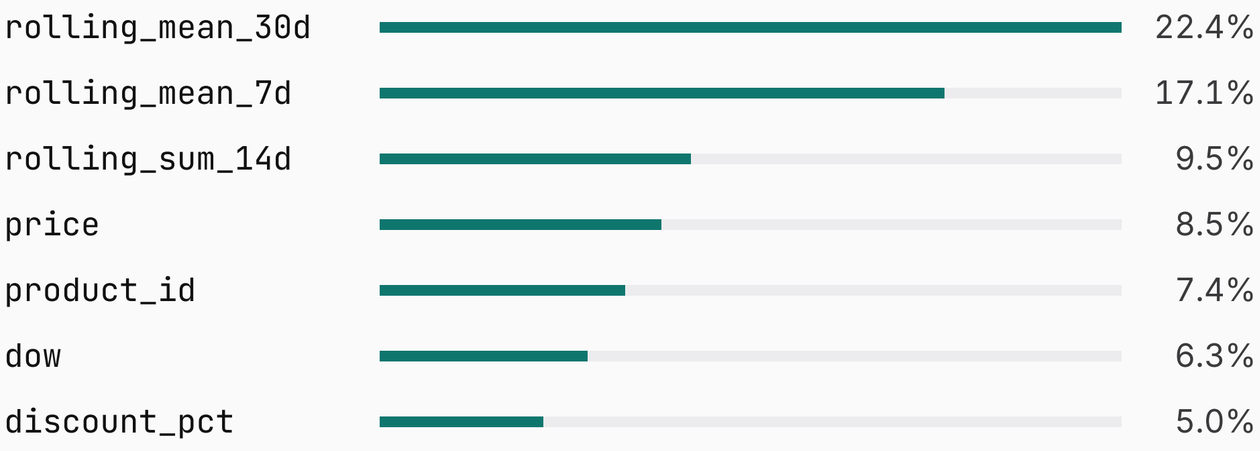

Rolling-группа суммарно — **~49%**. История продаж доминирует.

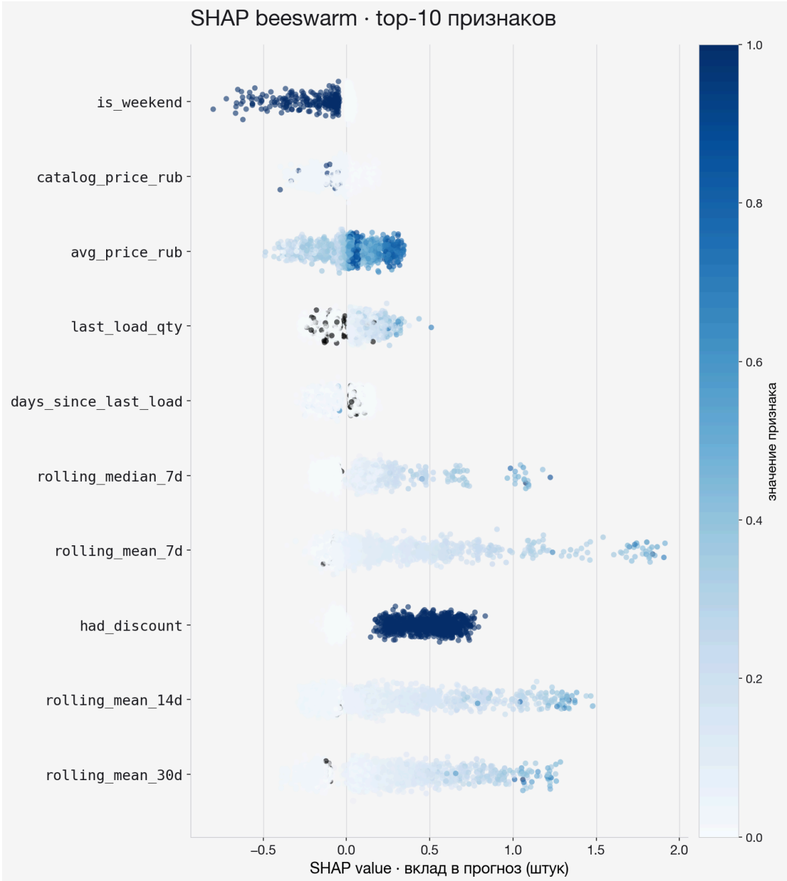

Рис. 6. SHAP подтверждает вывод: direction эффекта rolling-фич совпадает с ожиданием.

Сравнение моделей

МОДЕЛЬ	VAL MAE	TEST MAE	Δ VS. BASELINE
Rolling Mean 7d	0.658	0.712	baseline
CatBoost	0.549	0.597	−16.2%
XGBoost	0.572	0.606	−14.9%
LightGBM	0.550	0.599	−15.9%
НЕЙРОСЕТИ			
MLP	0.616	0.677	−4.9%
Conv1D	0.606	0.661	−7.2%

Единый fixed-rolling контракт: одинаковый split, один набор признаков и единая метрика MAE.

Что видно на сравнении

- CatBoost — лучший результат на едином сравнении
- Все бустинги уверенно лучше baseline
- Нейросети уступают на табличных данных
- CatBoost сочетает качество и интерпретируемость

Выводы и ошибки

TEST MAE

0.597

−16.2% vs. Rolling Mean 7d

СРЕДНЯЯ ОШИБКА

< 1 шт

По порядку величины — одна единица товара

ГЛАВНЫЙ РИСК

0 ≠ 0

Ноль продаж не равен нулевому спросу

Источник ошибки

Цензурированный спрос: если товар закончился, продажи падают до нуля, хотя реальный спрос мог остаться высоким.

СЛЕДУЮЩИЙ ШАГ

Спрос с учётом доступности товара. Явно моделировать факт наличия товара, обучаться только на днях с подтверждённой доступностью.

Доступность товара и следующие шаги

Ограничение текущей модели

Цензурированный спрос: ноль продаж при пустом слоте неотличим от нулевого спроса.

Шаг 1

Признаки доступности

is_available, hours_out_of_stock, refill_recency — из снимков остатков.

Шаг 2

Таргет с учётом доступности

Обучение только на днях с подтверждённой доступностью. Ожидается снижение систематического занижения.

Шаг 3

Оптимизация загрузки

От прогноза спроса к решению о загрузке: минимизация списаний и потерянных продаж.